دليل داتا مشروع التنبؤ باحتياج المحاصيل للمية

شرح كل عمود، والتارجت، وإزاي الداتا اتبنت وإزاي نستخدمها صح

إعداد: Ahmed Hamdy (جمع الداتا وتجهيزها) | مصادر: NASA POWER و SoilGrids و FAO-56 | أكتوبر 2026

1. الصورة الكبيرة
2. الملفات اللي هتلاقيها
3. مصادر الداتا
4. إزاي الداتا اتبنت
5. التارجت بالتفصيل
6. شرح كل عمود
7. أنهي أعمدة تدخل الموديل
8. التقسيم train / val / test
9. حالة البنود مقابل المهمة
10. حدود لازم تعرفها
11. إعادة بناء الداتا
ملاحق: جداول وقاموس مصطلحات

1. الصورة الكبيرة

المشروع بيتنبأ **باحتياج المحصول للمية**، يعني كام مم مية محتاجها في اليوم. مفيش داتا مفتوحة فيها كمية الري الفعلية للمزارع المصرية، فبنينا الداتا بنفسنا من مصادر علمية مفتوحة، وحسبنا احتياج الري بمعادلة FAO المعتمدة دوليا.

البند	القيمة
وحدة الصف	يوم واحد × محصول واحد × موقع واحد
حجم الداتا	حوالي 84 ألف صف، 26 عمود
الفترة	من 2015 لـ 2024
المواقع	10 مواقع من الدلتا لأسوان (الجدول في الملحق ب)
المحاصيل	6 محاصيل: قمح، ذرة، أرز، قطن، طماطم، بطاطس
التارجت	`IR_mm` : احتياج الري بالمم في اليوم

في جملة واحدة

بنجيب الطقس اليومي من NASA، ونحسب منه التبخر المرجعي ET0، ونضربه في معامل المحصول Kc حسب مرحلة نموه، ونطرح المطر المفيد، والناتج هو كمية الري المطلوبة.

2. الملفات اللي هتلاقيها

الملف	فيه إيه
`irrigation_dataset.csv`	الداتا الكاملة المدمجة (كل الأعمدة)
`test.csv` / `val.csv` / `train.csv`	نفس الداتا مقسومة بالزمن (التفاصيل في قسم 8)
`soil_by_location.csv`	خصائص التربة لكل موقع (لسه محتاجة تتملى، شوف قسم 3)
`data_dictionary.csv`	اسم كل عمود ومعناه ووحدته ومصدره

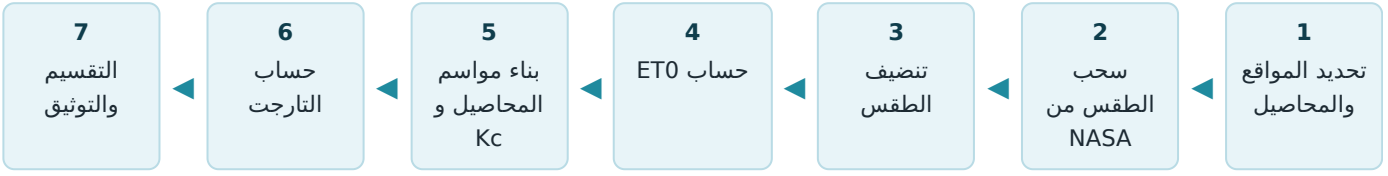
`sources_log.md`	روابط المصادر ومعاملات الـ API وتاريخ السحب
`cleaning_report.txt`	ملخص التنضيف: كام قيمة ناقصة واتصلحت
`locations.csv` / `crop_calendar.csv`	جداول المدخلات: المواقع، والمحاصيل بقيم Kc وأطوال المراحل
`build_irrigation_dataset.py`	السكريبت اللي بيبني كل ده من الأول بأمر واحد

3. مصادر الداتا

المصدر	بيدينا إيه	ملاحظات
NASA POWER	طقس يومي لأي إحداثيات: حرارة، رطوبة، رياح، إشعاع شمسي، مطر	مجاني بـ API. الشبكة خشنة (حوالي 50 كم)، فالأرقام تقديرية مش محطة أرضية.
SoilGrids (ISRIC)	التربة: رمل وطين وسلت و pH وكربون عضوي والسعة الحقلية ونقطة الذبول	الـ API رجع بيانات فاضية في آخر تجربة، فأعمدة التربة مش في الملف النهائي لسه.
FAO-56	معامل المحصول Kc وأطوال مراحل النمو لكل محصول	اتكتبوا يدويا في `crop_calendar.csv` ولازم يتراجعوا على جداول FAO (الجدول 11 و 12).
حساب ET0	التبخر المرجعي بمعادلة Penman-Monteith	بيتحسب في السكريبت من الطقس، مش بيتحمل من مكان.

> **ليه مفيش Roboflow في الداتا؟**
>
> داتا Roboflow كلها صور (object detection)، فمش بتدخل في نموذج بيتنبأ برقم زي كمية المية. تنفع بس لو الفريق هيضيف جزء Computer Vision (تحديد نوع المحصول أو مرحلة النمو). لسه محدش اختار dataset منها.

4. إزاي الداتا اتبنت



1. **تحديد المواقع والمحاصيل:** 10 مواقع (إحداثيات) و 6 محاصيل، وكل محصول ليه تاريخ زراعة وأطوال مراحل.
2. **سحب الطقس:** لكل موقع بنسحب 7 متغيرات يومية من 2015 لـ 2024. القيمة `-999` معناها ناقصة وبتتحول NaN.
3. **تنضيف الطقس:** نشيل القيم المستحيلة (رطوبة برا 0 لـ 100، حرارة برا المدى، Tmax أقل من Tmin، إشعاع سالب)، ونملا الفجوات الصغيرة (3 أيام أو أقل) بالاستيفاء، ونحذف المكرر.
4. **حساب ET0:** بمعادلة FAO-56 Penman-Monteith من الحرارة والرطوبة والرياح والإشعاع وارتفاع الموقع وخط العرض.
5. **بناء المواسم:** لكل موقع ومحصول وسنة، بنعمل صف لكل يوم من الزراعة لحد آخر الموسم، ونحسب Kc اليومي من منحنى المراحل الأربعة.
6. **حساب التارجت:** $ETc = Kc \times ET0$، بعد كده نطرح المطر الفعّال (قسم 5).

7. **الفحص والتقسيم والتوثيق:** نشيل الصفوف الناقصة، ونقسم بالزمن لـ train و val و test، ونطلع data_dictionary و sources_log.

5. التارجت بالتفصيل

> **التارجت هو عمود `IR_mm`**
>
> احتياج الري اليومي بالمم لمحصول معين في موقع معين. وعمود `IR_m3_feddan` هو نفس الرقم بس بالمتر المكعب للفدان، فاستخدم واحد منهم بس كتارجت.

المعادلات

```
ET0 = [0.408 Δ (Rn - G) + γ (900 / (T + 273)) u2 (es - ea)] / [Δ + γ (1 + 0.34 u2)]   (FAO-56 Penman-Monteith)
ETc = Kc × ET0
rain_eff = 0.8 × rain   (لو rain ≥ 5 mm)  وإلا 0
IR_mm = max( ETc - rain_eff , 0 )
IR_m3_feddan = IR_mm × 4.2
```

- **ET0:** كمية المية اللي بتتبخر من مسطح عشب مرجعي في الظروف دي. بتتحسب من الطقس بس، ومش بتعتمد على المحصول.
- **Kc:** معامل بيحول التبخر المرجعي لاحتياج المحصول الفعلي. بيبدأ صغير (المحصول لسه صغير)، ويكبر لحد منتصف الموسم، وبعدين ينزل في الآخر.
- **المطر الفعّال:** الجزء من المطر اللي المحصول بيستفيد منه فعلا. بنفترض 80% من المطر لو اليوم نزل فيه 5 مم أو أكتر، وإلا صفر. ده تبسيط، وممكن يتحسن بعدين.
- **max(... , 0):** لو المطر الفعّال أكبر من احتياج المحصول، الري المطلوب صفر، مش رقم سالب.
- **4.2:** الفدان 4200 م²، ومم واحد من المية على فدان = 4.2 م³.

مثالين من الداتا نفسها (طنطا، قطن، موسم 2015)

	يوم عادي (اليوم 0)	يوم مطير (اليوم 17)
`rain_mm`	0	30.27
`ET0_mm`	4.509	2.658
`Kc`	0.35	0.35
`ETc_mm` = Kc × ET0	1.578 = 4.509 × 0.35	0.930 = 2.658 × 0.35
`rain_eff_mm`	0	24.216 = 30.27 × 0.8
`IR_mm` (التارجت)	**1.578**	**0** (المطر أكبر من الاحتياج)
`IR_m3_feddan`	6.63 = 4.2 × 1.578	0

نقطة مهمة جدا

التارجت **محسوب بمعادلة** مش مقاس من الأرض. وعشان كده لو الموديل شاف الطقس الخام (حرارة ورطوبة ورياح وإشعاع) هو في الحقيقة بيتعلم يقلد معادلة FAO. شوف قسم 7 لطرق استخدام الداتا صح.

لو الفريق عايز تصنيف بدل الرقم: ممكن نعمل عمود `IR_class` (Low / Medium / High) بتقسيم `IR_mm` بحدود واضحة (مثلا حسب الربعيات)، بس لازم نتفق على الحدود ونوثقها.

6. شرح كل عمود

الأعمدة الـ 26 في الملف مقسومة لـ 5 مجموعات. عمود **الدور** بيقولك الأخضر ينفع feature، والأحمر لازم يتشال من التدريب، والرمادي معرّفات.

أ. تعريف الصف والموقع

العمود	المعنى	الوحدة	المصدر	الدور
`date`	تاريخ اليوم	YYYY-MM-DD	مبني	معرّف: شيله
`loc_id`	رقم الموقع (1 لـ 10)	-	locations.csv	اختياري
`loc_name`	اسم الموقع، مثلا Tanta_Gharbia أو Aswan	-	locations.csv	معرّف: شيله
`lat`	خط العرض	درجة	locations.csv	اختياري
`lon`	خط الطول	درجة	locations.csv	اختياري
`elev_m`	ارتفاع الموقع عن سطح البحر، مستخدم في حساب ET0	متر	NASA POWER	اختياري
`season_year`	السنة اللي المحصول اتزرع فيها (قمح اتزرع نوفمبر 2015 بيخلص 2016 وسنته 2015)	-	مبني	معرّف: شيله
`split`	القسم اللي الصف تابع له: train أو val أو test	-	مبني	معرّف: شيله

ب. الطقس (من NASA POWER)

العمود	المعنى	الوحدة	المصدر	الدور
`Tmean`	متوسط حرارة اليوم عند ارتفاع 2 متر	°C	T2M	Feature
`Tmax`	أعلى حرارة في اليوم	°C	T2M_MAX	Feature
`Tmin`	أقل حرارة في اليوم	°C	T2M_MIN	Feature
`RH`	الرطوبة النسبية عند 2 متر	%	RH2M	Feature
`wind_2m`	سرعة الرياح عند 2 متر	م/ث	WS2M	Feature
`Rs`	الإشعاع الشمسي الواصل للأرض (كل الظروف الجوية)	MJ/m²/day	ALLSKY_SFC_SW_DWN	Feature

`rain_mm`	كمية المطر في اليوم (بعد التصحيح)	مم/يوم	PRECTOTCORR	Feature

ج. المحصول والموسم

العمود	المعنى	الوحدة	المصدر	الدور
`crop`	نوع المحصول: wheat, maize, rice, cotton, tomato, potato	-	crop_calendar.csv	Feature
`days_after_planting`	عدد الأيام من يوم الزراعة (يبدأ من 0)	يوم	مبني	Feature
`stage`	مرحلة النمو: initial, development, mid, late (حسب أطوال المراحل في الملحق أ)	-	FAO-56	Feature
`doy`	رقم اليوم في السنة (1 لـ 366)، بيعبر عن الموسم	يوم	مبني	Feature
`month`	رقم الشهر (1 لـ 12)	-	مبني	Feature

د. حسابات وسيطة (بتسرّب التارجت)

العمود	المعنى	الوحدة	المصدر	الدور
`ET0_mm`	التبخر المرجعي بمعادلة Penman-Monteith	مم/يوم	محسوب	تسريب: شيله
`Kc`	معامل المحصول في مرحلة اليوم ده	-	FAO-56	تسريب: شيله
`ETc_mm`	احتياج المحصول = Kc × ET0	مم/يوم	محسوب	تسريب: شيله
`rain_eff_mm`	المطر الفعّال: 80% من المطر لو أكبر من 5 مم	مم/يوم	محسوب	تسريب: شيله

هـ. التارجت

العمود	المعنى	الوحدة	المصدر	الدور
`IR_mm`	احتياج الري = max(ETc - المطر الفعّال, 0)	مم/يوم	محسوب	Target
`IR_m3_feddan`	نفس التارجت بالمتر المكعب للفدان (× 4.2)	م³/فدان/يوم	محسوب	Target

و. أعمدة التربة (مش موجودة في الملف الحالي)

دي هتتضاف تلقائيا لما سحب SoilGrids يشتغل. هي ثابتة لكل موقع (مش بتتغير بالأيام).

العمود	المعنى	الوحدة	المصدر	الدور
`sand_pct / silt_pct / clay_pct`	نسب الرمل والسلت والطين (متوسط 0 لـ 60 سم)	%	SoilGrids	قادم
`soil_pH`	درجة حموضة التربة	pH	SoilGrids	قادم
`soc_g_kg`	الكربون العضوي في التربة	جم/كجم	SoilGrids	قادم

`FC_m3m3`	السعة الحقلية: أقصى مية التربة بتمسكها	م³/م³	SoilGrids	قادم
`WP_m3m3`	نقطة الذبول: أقل مية متاحة للنبات	م³/م³	SoilGrids	قادم
`TAW_mm_per_m`	المية المتاحة للنبات في كل متر تربة = (FC - WP) × 1000	مم/م	محسوب	قادم

7. أنهي أعمدة تدخل الموديل

الفئة	الأعمدة	ليه
Feature Features	`Tmean, Tmax, Tmin, RH, wind_2m, Rs, rain_mm, crop, days_after_planting, stage, doy, month` اختياري: `loc_id, lat, lon, elev_m`	معلومات متاحة قبل ما نعرف الإجابة
Target Target	`IR_mm` (أو `IR_m3_feddan` ، واحد بس)	الحاجة اللي عايزين نتنبأ بيها
تسريب: شيله شيلهم	`ET0_mm, Kc, ETc_mm, rain_eff_mm, IR_m3_feddan`	التارجت محسوب منهم، فلو دخلوا الموديل هيحفظ المعادلة ويطلع دقة وهمية (data leakage)
معرّف: شيله شيلهم	`date, loc_name, season_year, split`	معرّفات وأعمدة تحكم مش معلومات تنبؤية

> **حتى بعد ما تشيل أعمدة التسريب**
>
> الحرارة والرطوبة والرياح والإشعاع هم نفس مدخلات معادلة ET0، والتارجت = دالة Kc × ET0. فموديل ML على الأعمدة دي هيقدر يوصل لدقة عالية جدا بس لأنه اتعلم المعادلة، مش لأنه اكتشف حاجة جديدة. ده مش خطأ تقني، بس لازم الفريق يعرف إيه اللي بيقيسه.

تلات طرق نستخدم بيها الداتا صح

1. **تنبؤ بالمستقبل (forecasting):** نخلي الموديل يتنبأ باحتياج اليوم الجاي أو الأسبوع الجاي من طقس الأيام السابقة (lag features)، فتبقى مشكلة تنبؤ حقيقية مش حساب مباشر.
2. **تقدير بمدخلات ناقصة:** لو في الواقع المتاح بس الحرارة والمطر (مفيش رياح ولا إشعاع)، نستخدم الموديل كبديل سريع لمعادلة FAO الكاملة، ونقارن دقته بمعادلات أبسط زي Hargreaves.
3. **داتا ري حقيقية:** لو لقينا قياسات ري فعلية (مزرعة أو دراسة)، تبقى هي التارجت، والمحسوب يتحول لـ baseline للمقارنة.

8. التقسيم train / val / test

التقسيم **بالزمن** مش عشوائي. السبب إن الأيام المتتالية شبه بعض جدا، فلو قسمنا عشوائي هيبقى في أيام جنب بعض في train و test، والموديل هيطلع أحسن من الحقيقة.

القسم	السنين	عدد الصفوف تقريبا	الاستخدام
train	2015 لـ 2021	59 ألف	تدريب الموديل
val	2022	8.5 ألف	ضبط الإعدادات واختيار الموديل
test	2023 لـ 2024	16.6 ألف	التقييم النهائي مرة واحدة بس

التقسيم بيتحدد بسنة اليوم نفسه (`date`) مش بسنة الموسم، وممكن يتغير من السكريبت بالمعامل `--train-end` .

9. حالة البنود مقابل المهمة الأصلية

البند	الحالة	ملاحظة
اختيار الداتا سيتس المناسبة	جزئي	مصادر الطقس والتربة والمحاصيل اتحددت. لسه ما اتحددش dataset من Roboflow. داتا Kaggle للري اتقيّمت وطلعت اصطناعية، فمساعدة بس.
جمع بيانات الطقس	تم	NASA POWER، 10 مواقع، 2015 لـ 2024
جمع بيانات التربة	جزئي	الكود جاهز لكن SoilGrids لسه مرجعش قيم
جمع بيانات المحاصيل	جزئي	Kc وأطوال المراحل مكتوبين يدويا ومحتاجين مراجعة على FAO-56
بيانات الري والإنتاجية الفعلية	لسه	ما اتلقتش داتا مفتوحة. التارجت محسوب بالمعادلة.
تنضيف الداتا (ناقص، مكرر، متطرف، خطأ)	تم	مطبق على الطقس، والتفاصيل في cleaning_report.txt
توحيد الوحدات	تم	°C، مم، م/ث، MJ/m²/يوم، م³/فدان
الربط (تاريخ، محصول، موقع)	تم	مفتاح الصف: loc_id + crop + date
EDA أساسي	لسه	لسه ما اتعملش (إحصائيات، توزيعات، ارتباطات، رسومات)
تحديد الـ features والـ target	تم	موثق في الدليل ده (قسم 7)
الداتا النهائية المدمجة	تم	irrigation_dataset.csv
التقسيم train / val / test	تم	بالزمن (قسم 8)
توثيق المصادر ومعاني الأعمدة	جزئي	data_dictionary و sources_log موجودين. محتاجين تحديث بعد إضافة التربة.

10. حدود لازم تعرفها

1. **التارجت مشتق مش مقاس.** مفيش قياسات ري فعلية، ودي أهم نقطة تتقال لأي حد هيستخدم الداتا (قسم 7).
2. **أرقام Kc وأطوال المراحل وتواريخ الزراعة** اتكتبت كقيم مبدئية، ولازم تتراجع على FAO Irrigation and Drainage Paper 56 (الجدول 11 و 12) وعلى التقويم الزراعي المصري.
3. **ET0 ممكن يكون أعلى شوية من المحطات الأرضية** لأن NASA POWER شبكة خشنة. ومحتاجين مقارنة مع مصدر تاني (Open-Meteo أو CLIMWAT) قبل الاعتماد النهائي.
4. **المطر الفعّال مبسّط:** 80% من المطر لو 5 مم أو أكتر. في طرق أدق تعتمد على التربة.

5. **الأرز:** الرقم هو ETc بس، من غير فقد الترشيح (percolation) وتجهيز الغمر، فاحتياج الرز الفعلي أعلى.
6. **إحداثيات المواقع تقريبية** (مدن المحافظات)، ومش حقول بعينها. ولو عندكم حقل محدد، غيّروا `locations.csv`.
7. **مفيش صور أو بيانات حساسات حقلية** في الداتا دي.

11. إعادة بناء الداتا

```
pip install requests pandas numpy
python build_irrigation_dataset.py   # بيعمل أول مرة: locations.csv و crop_calendar.csv ويقف
# عدّل الملفين، وبعدين شغّله تاني:
python build_irrigation_dataset.py --start-year 2015 --end-year 2024
python build_irrigation_dataset.py --skip-soil   # من غير سحب التربة
```

- الردود من الـ API بتتخزن في `data/raw/` فمش بيسحب تاني.
- لو الملف مفتوح في Excel، السكريبت بيحفظ نسخة باسم `_NEW` بدل ما يقع.
- داخل Jupyter أو Colab استخدم `main()` أو `%run build_irrigation_dataset.py`.

ملحق أ: المحاصيل وقيم Kc الافتراضية

قيم مبدئية

القيم دي الافتراضية في السكريبت وبتتعدل من `crop_calendar.csv` . راجعها على FAO-56 قبل ما تعتمد عليها.

المحصول	تاريخ الزراعة	أيام المراحل (initial / dev / mid / late)	طول الموسم	Kc (ini / mid / end)
wheat (قمح)	15 نوفمبر	30 / 50 / 25 / 15	120 يوم	0.25 / 1.15 / 0.30
maize (ذرة)	15 مايو	30 / 40 / 35 / 20	125 يوم	0.35 / 1.20 / 0.30
rice (أرز)	15 مايو	30 / 60 / 30 / 30	150 يوم	0.90 / 1.20 / 1.05
cotton (قطن)	25 مارس	55 / 60 / 50 / 30	195 يوم	0.70 / 1.15 / 0.35
tomato (طماطم)	15 فبراير	25 / 40 / 40 / 30	135 يوم	0.80 / 1.15 / 0.60
potato (بطاطس)	20 يناير	30 / 45 / 30 / 25	130 يوم	0.75 / 1.15 / 0.50

منحنى Kc: ثابت على قيمة `Kc_ini` في المرحلة الأولى، وبيطلع بشكل خطي في مرحلة النمو لحد `Kc_mid` ، وثابت في المنتصف، وبعدين بينزل بشكل خطي لـ `Kc_end` في آخر الموسم.

ملحق ب: المواقع (إحداثيات تقريبية)

loc_id	الموقع	lat	lon
1	Tanta (الغربية)	30.79	31.00
2	Damanhour (البحيرة)	31.04	30.47
3	Zagazig (الشرقية)	30.59	31.50
4	Giza (الجيزة)	30.01	31.21
5	Fayoum (الفيوم)	29.31	30.84
6	Minya (المنيا)	28.11	30.75
7	Assiut (أسيوط)	27.18	31.18
8	Sohag (سوهاج)	26.56	31.70
9	Qena (قنا)	26.16	32.72
10	Aswan (أسوان)	24.09	32.90

ملحق ج: قاموس المصطلحات

المصطلح	معناه ببساطة
ET0	التبخر النتحي المرجعي: كمية المية اللي بتفقدها أرض مزروعة عشب مرجعي في اليوم حسب الطقس.
Kc	معامل المحصول: رقم بيحول ET0 لاحتياج محصول معين في مرحلة نموه.
ETc	احتياج المحصول من المية = Kc × ET0.
Penman-Monteith	المعادلة اللي FAO اعتمدتها لحساب ET0 من الحرارة والرطوبة والرياح والإشعاع.
المطر الفعّال	الجزء من المطر اللي بيفيد المحصول فعلا (مش اللي بيسيح أو بيتبخر).
السعة الحقلية (FC)	أقصى كمية مية التربة بتمسكها بعد ما الزيادة تنزل.
نقطة الذبول (WP)	مستوى رطوبة التربة اللي النبات مش بيقدر ياخد بعده مية.
الفدان	وحدة مساحة مصرية = 4200 م² (حوالي 0.42 هكتار).
Feature / Target	الـ feature هو المدخل للموديل، والـ target هو الحاجة اللي عايزين نتنبأ بيها.
Data leakage	لما الموديل يشوف في التدريب معلومة بتكشف الإجابة، فبيطلع نتيجة حلوة وهمية ومش هتتكرر في الواقع.
Interpolation	ملء القيمة الناقصة من القيم اللي حواليها (بنستخدمها لفجوات 3 أيام أو أقل).
NaN	قيمة ناقصة أو غير معروفة في الجدول.